## Projetos em Ciência de Dados

Gianlucca Devigili e Maisa O. Fraiz

# 1. Preparação dos Dados


#### Tratamento de Dados

- + Dados salvos em .pkl
  - + Redução do tempo de carga de 28.4s para 5.34s
  - + Redução do uso de memória RAM
  - + Redução do espaço em disco de 3.8GB para 3.4GB


## Higienização e Separação dos dados


- + Padronização dos nomes de colunas
- Remoção de colunas que representam o mesmo dado (e.g. nome e sigla do time)
- + Redução do tamanho dos arquivos
- + Encapsulamento dos dados

# Higienização e Separação dos dados



# Higienização e Separação dos dados





# 2. Análise Exploratória


### Estatísticas de Resumo dos Targets


# describe the targets
trg\_cols = ['target1', 'target2', 'target3', 'target4']
round(targets[trg\_cols].describe(), 2)


	target1	target2	target3	target4
count	2506176.00	2506176.00	2506176.00	2506176.00
mean	0.57	2.46	0.69	1.14
std	4.17	6.23	5.07	4.23
min	0.00	0.00	0.00	0.00
25%	0.00	0.08	0.00	0.05
50%	0.00	0.56	0.00	0.22
75%	0.02	2.24	0.02	0.76
max	100.00	100.00	100.00	100.00


- + 2 milhões de registros
- + Os targets variam de 0 a 100
- Médias baixas
- + Maioria dos valores 0 ou próximos de 0

# Histograma dos targets











## Histograma dos targets em escala logarítmica




## Boxplot dos Targets




## Correlação Entre os Targets


	target1	target2	target3	target4
target1	1.000000	0.404532	0.411024	0.384962
target2	0.404532	1.000000	0.388134	0.548991
target3	0.411024	0.388134	1.000000	0.370333
target4	0.384962	0.548991	0.370333	1.000000




## Scatterplot dos Targets



## Média diária dos Targets




### Média dos Targets ao longo do tempo




Mediana dos Targets ao longo do tempo









## Projetos em Ciência de Dados

Gianlucca Devigili e Maisa O. Fraiz